

6.4.1～6.4.2 ガウス過程による回帰

平成 28 年 9 月 11 日

概 要

PRML の「6.4.1 線形回帰再訪」「6.4.2 ガウス過程による回帰」についての実装と考察.

目 次

1	問題設定	2
2	アルゴリズム	2
3	コード	3
4	結果	3
4.1	ガウスカーネル	3
4.2	多項式カーネル	4
5	超パラメータの学習	6
6	関連度自動決定	6
7	まとめ	6

1 問題設定

t_n がガウス分布に従っているものをガウス過程という. このガウス過程について考察する. ここでは, ガウス過程による回帰を行う.

2 アルゴリズム

まず, 観測される目標変数の値にはノイズが含まれるとする.

$$t_n = y_n + \epsilon_n \quad (6.57)$$

そして, このノイズはガウス分布に従うとする.

$$p(t_n|y_n) = N(t_n|y_n, \beta^{-1}) \quad (6.58)$$

これを N 個の観測地についてまとめると

$$p(\mathbf{t}|\mathbf{y}) = N(\mathbf{t}|\mathbf{y}, \beta^{-1}I) \quad (6.59)$$

となる.

また, ガウス過程の過程から $p(\mathbf{y})$ は

$$p(\mathbf{y}) = N(\mathbf{y}|\mathbf{0}, K) \quad (6.60)$$

となる. ここで, K はグラム行列. ただし, (i, j) 成分は x_i, x_j の相関度合いによって決まるものである必要がある.

入力 x_1, \dots, x_N で条件づけられた周辺確率分布 $p(\mathbf{t})$ は (線形ガウスモデル)

$$p(\mathbf{t}) = \int p(\mathbf{t}|\mathbf{y})p(\mathbf{y})d\mathbf{y} = N(\mathbf{t}|\mathbf{0}, C) \quad (6.61)$$

ここで共分散行列 C は

$$C(x_n, x_m) = k(x_n, x_m) + \beta^{-1}\delta_{nm} \quad (6.62)$$

また, カーネル関数には

$$k(x_n, x_m) = \theta_0 \exp\{-\frac{\theta_1}{2}\|x_n - x_m\|^2\} + \theta_2 + \theta_3 x_n^T x_m \quad (6.63)$$

がよく用いられる.

次に, 条件付き分布 $p(t_{N+1}|\mathbf{t})$ を求めるが, まず $p(\mathbf{t}_{N+1})$ については (6.61) と同様にして

$$p(\mathbf{t}_{N+1}) = N(\mathbf{t}_{N+1}|\mathbf{0}, C_{N+1}) \quad (6.64)$$

となり, 共分散行列は

$$C_{N+1} = \begin{pmatrix} C_N & \mathbf{k} \\ \mathbf{k}^T & c \end{pmatrix} \quad (6.65)$$

で, \mathbf{k} は成分 n に $k(x_n, x_{N+1})$ に持つベクトルで, スカラー $c = k(x_{N+1}, x_{N+1}) + \beta^{-1}$ とする. 分割されたガウス分布についての結果から

$$m(x_{N+1}) = \mathbf{k}^T C_N^{-1} \mathbf{t} \quad (6.66)$$

$$\sigma^2(x_{N+1}) = c - \mathbf{k}^T C_N^{-1} \mathbf{k} \quad (6.67)$$

これは x_{N+1} に対する予測分布のパラメータととらえられる.

3 コード

予測分布のパラメータを求める (kaiki.py).

```
"""カーネル関数の定義"""
theta=0.05
def gauss(x,z):
    return np.exp(-(x-z)**2/2*N*theta)

"""Wの最適化"""
print("gauss")
for N in [10,30,50,100]:
    x=data[:N,0]
    t=data[:N,1]
    C=np.identity(N)*(0.3**2)
    s=2*(2*pi)/N

    for n in range(N):
        for m in range(N):
            C[n,m]+=gauss(x[n],x[m])

    #x=pi に対する予測分布の平均
    print(model_f(pi))
    #x=pi に対する予測分布の分散
    k=[gauss(x[n],pi) for n in range(N)]
    print(gauss(pi,pi)+1/0.3**2-dot(k,dot(inv(C),k)))

    #求まったパラメータからモデル関数を作り
    def model_f(z):
        k=[gauss(x[n],z) for n in range(N)]
        return dot(k,dot(inv(C),t))
```

4 結果


4.1 ガウスカーネル

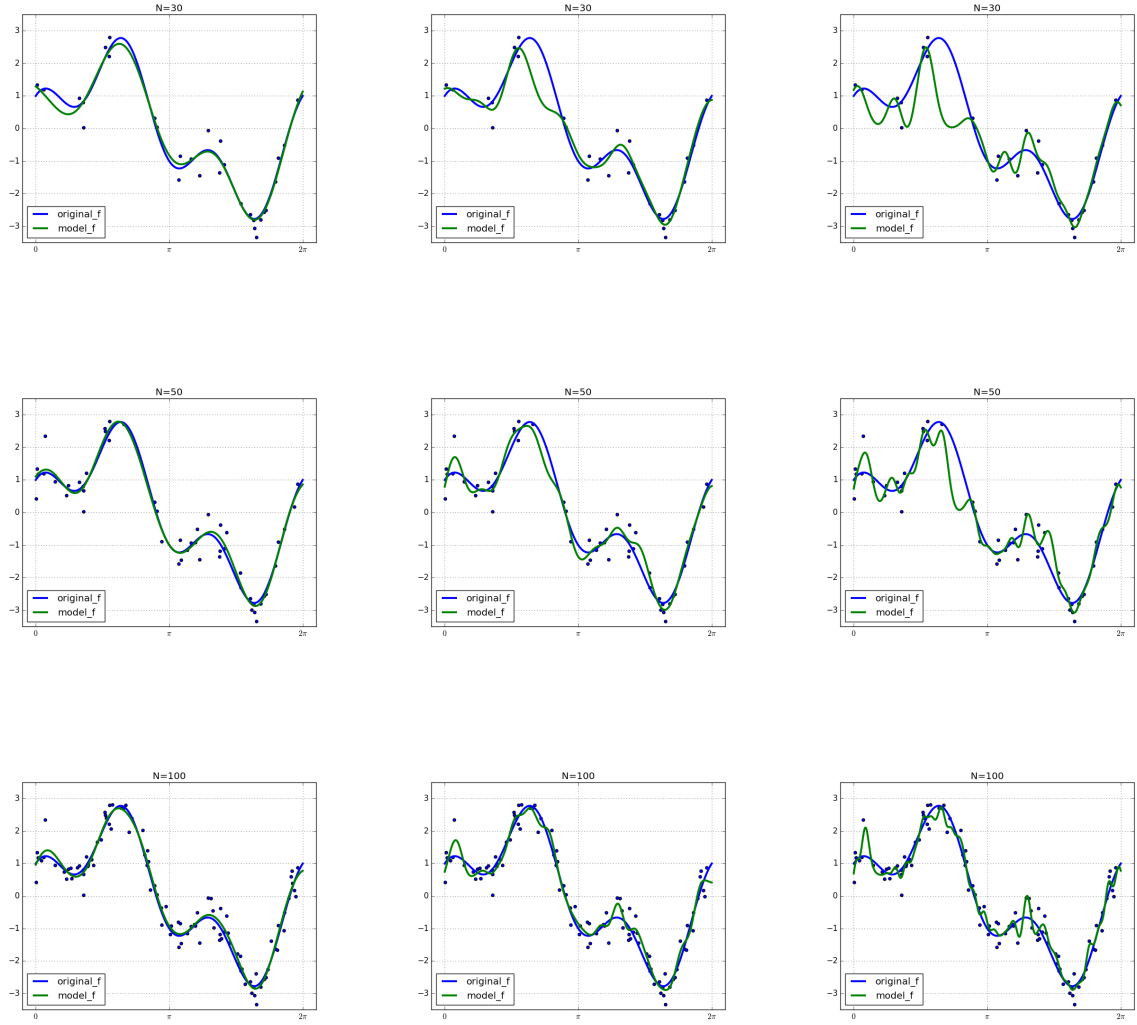
予測分布の平均をプロットする.

ここでは, $\beta = 1/0.3^2$ としカーネル関数に

$$k(x_n, x_m) = \exp\left\{-\frac{\theta}{2}(x_n - x_m)^2\right\}$$

を用いて, $\theta = 0.05 \times N, 0.3 \times N, 1 \times N$ としてデータ数 $N = 10, 30, 50, 100$ にそれぞれ試してみた





$\theta \backslash N$	10	30	50	100
$0.05 \times N$	1.212	0.332	0.297	0.282
$0.3 \times N$	4.432	0.665	0.405	0.332
$1 \times N$	0.869	1.069	0.684	0.389

表 1: N と E, θ の関係

データ数によって最適なパラメータも変化すると考えられる。パラメータの最適化が重要になる。

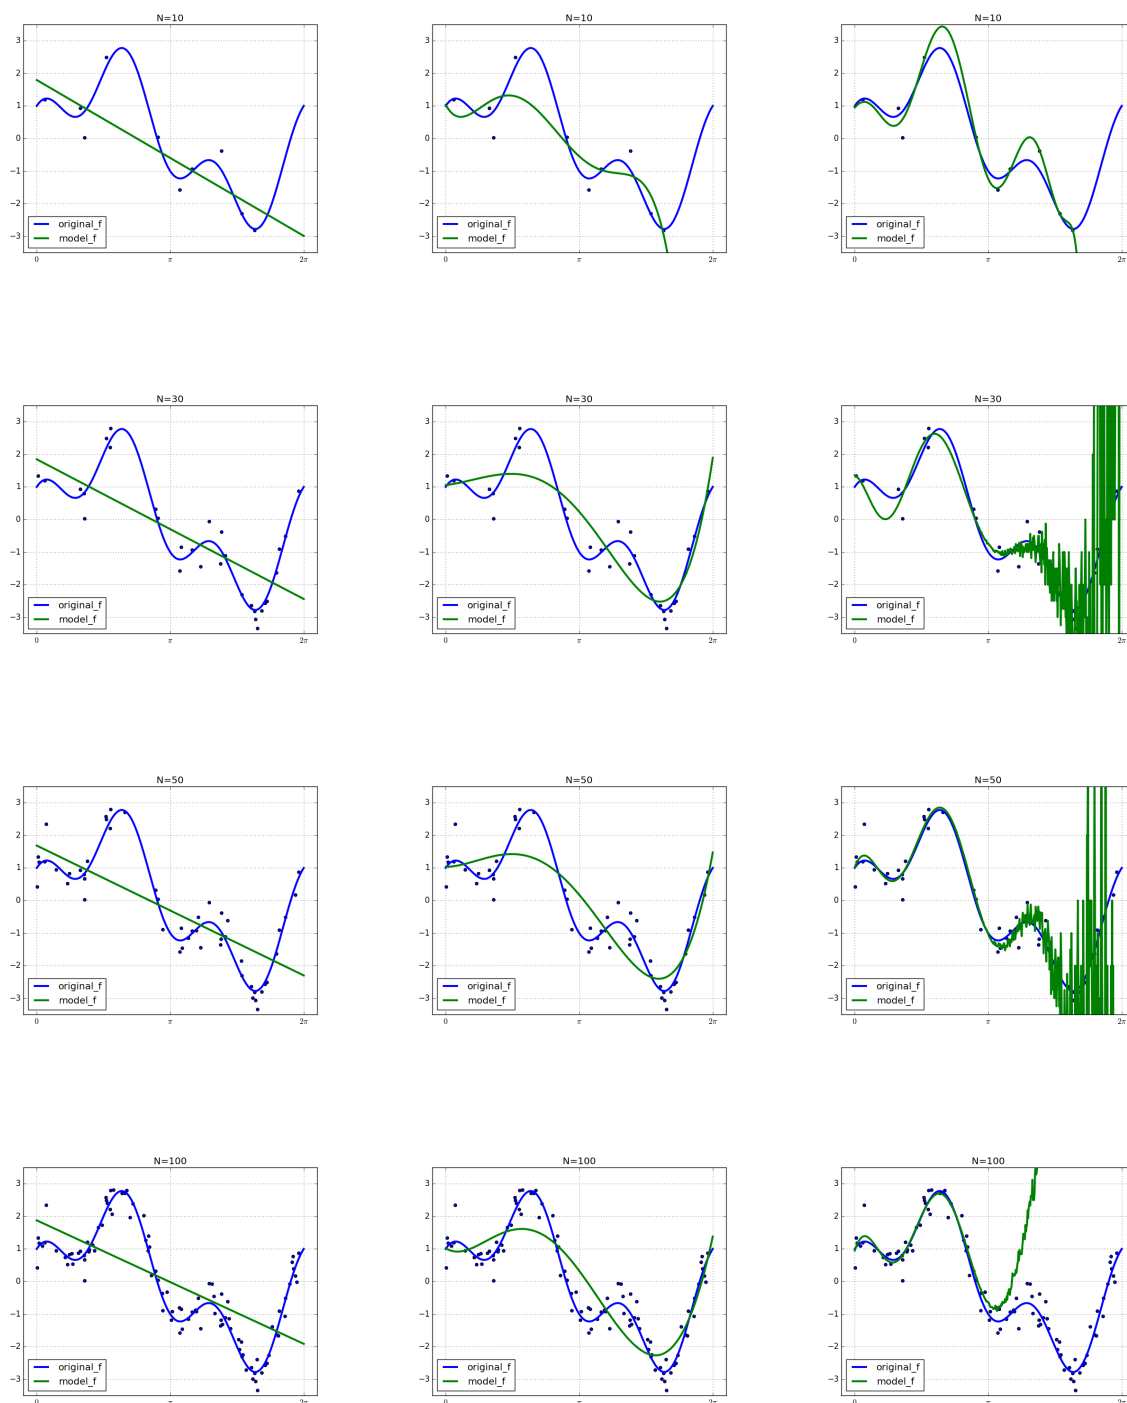
また、予測分布のパラメータは $(N = 100, \theta = 0.05)$ で $x = \pi$ に対し、平均 $= -0.925$ (正解 $t = -1$)、分散 $= 11.126$ (正解 $\beta = 1/0.3^2$) となり両方とも正解に近くなっている。これは回帰が成功したものではおおよそ同じ結果となった。

4.2 多項式カーネル

ここでは、 $\beta = 1/0.3^2$ としカーネル関数に

$$k(x_n, x_m) = (x_n x_m + 1)^\theta$$

を用いて, $\theta = 1, 5, 10$ としてデータ数 $N = 10, 30, 50, 100$ にそれぞれ試してみた



$\theta \backslash N$	10	30	50	100
1	1.510	1.350	1.345	1.257
5	5.689	0.821	0.803	0.736
10	126.486	3.899	7.965	31.603

表 2: N と E, θ の関係

絶対値の大きな区間と小さな区間とで回帰の成功度合いが異なる。絶対値の大きな区間では回帰が難しくなってしまう。

また、分散が正解と大きく異なる (分散が非常に大きい場合) 回帰がうまくいっていない傾向がみられる。

5 超パラメータの学習

$p(\mathbf{t}|\theta)$ は

$$p(\mathbf{t}|\theta) = N(\mathbf{t}|\mathbf{0}, C_N) \quad (6.61)'$$

となるため、この対数を θ について最大化する。

$$\ln p(\mathbf{y}|\theta) = -\frac{1}{2}|C_N| - \mathbf{t}^T C_N^{-1} \mathbf{t} - \frac{N}{2} \ln(2\pi) \quad (6.69)$$

また、 θ はカーネル関数のパラメータなので、 C_N に暗に含まれており、上の対数の θ_i による微分は

$$\frac{\partial \ln p(\mathbf{y}|\theta)}{\partial \theta_i} = -\frac{1}{2} \text{Tr} \left(C_N^{-1} \frac{\partial C_N}{\partial \theta_i} \right) + \frac{1}{2} \mathbf{t}^T C_N^{-1} \frac{\partial C_N}{\partial \theta_i} \mathbf{t} \quad (6.70)$$

となるが、 $\ln p(\mathbf{t}|\theta)$ は一般に非凸関数なので複数の極大点を持つ。ただし完全にベイズ的に扱うには θ の事前分布との積を最大化する必要がある、これには近似を用いる。

6 関連度自動決定

入力が多次元であるとき、どの変数が学習にどの程度影響を与えるかを知ることができる。カーネル関数に

$$k(\mathbf{x}, \mathbf{z}) = \theta_0 \exp -\frac{1}{2} \sum_i \eta_i (x_i - z_i)^2 \quad (6.71)$$

を用いて、最尤推定からパラメータ η をデータに適応させる。このパラメータ η が、学習への影響度合いを示す。

7 まとめ

ガウスカーネルは結構うまくいったが、多項式カーネルはやはりうまくいかない。また、カーネル関数のパラメータを最適化する必要も大きい、結構式がややこしくなって難しそう。