

## 10.3 変分線形回帰

平成 28 年 9 月 11 日

### 概 要

PRML の「10.3 変分線形回帰」についての実装と考察

### 目 次

1	問題設定	2
2	アルゴリズム	2
3	コード	3
4	結果	4
4.1	多項式基底 . . . . .	4
4.2	ガウス基底 . . . . .	5
4.3	シグモイド基底 . . . . .	6
4.4	tanh 基底 . . . . .	6
5	まとめ	7

## 1 問題設定

線形回帰を行う。超パラメータ  $\alpha, \beta$  についてエビデンス近似ではなく変分近似で近似してみる。

## 2 アルゴリズム

線形回帰では、超パラメータまで最適化しようとする、解析的に解くことのできない積分が出てきた。今まで、これをエビデンス近似で対処してきたが、ここでは変分近似を用いてみる。(ただし、 $\beta$  は既知とする)

まず、 $\mathbf{w}$  に対する尤度関数と  $\mathbf{W}$  の事前分布は、

$$p(\mathbf{t}|\mathbf{w}) = \prod_{n=1}^N N(t_n|\mathbf{w}^T \boldsymbol{\phi}_n, \beta^{-1}) \quad (10.87)$$

$$p(\mathbf{w}|\alpha) = N(\mathbf{w}|\mathbf{0}, \alpha^{-1}I) \quad (10.88)$$

とする。また、 $\alpha$  の事前分布は共役事前分布として

$$p(\alpha) = G(\alpha|a_0, b_0) \quad (10.89)$$

を選ぶ。以上より、すべての変数の同時分布は

$$p(\mathbf{t}, \mathbf{w}, \alpha) = p(\mathbf{t}|\mathbf{w})p(\mathbf{w}|\alpha)p(\alpha) \quad (10.90)$$

となる。

ここでの目標は事後分布  $p(\mathbf{w}, \alpha|\mathbf{t})$  の近似を求めることなので、このため分解される変分事後分布を考える。

$$q(\mathbf{w}, \alpha) = q(\mathbf{w})q(\alpha) \quad (10.91)$$

まず、 $\ln q(\alpha)$  は

$$\begin{aligned} \ln q^*(\alpha) &= \ln p(\alpha) + E_{\mathbf{w}}[\ln p(\mathbf{w}|\alpha)] + \text{const} \\ &= (a_0 - 1) \ln \alpha - b_0 \alpha + \frac{M}{2} \ln \alpha - \frac{\alpha}{2} E[\mathbf{w}^T \mathbf{w}] + \text{const} \end{aligned} \quad (10.92)$$

これは、ガンマ分布の対数であり

$$q^*(\alpha) = \text{Gam}(\alpha|a_N, b_N) \quad (10.93)$$

となる。ここで

$$a_N = a_0 + \frac{M}{2} \quad (10.94), \quad b_N = b_0 + \frac{1}{2} E[\mathbf{w}^T \mathbf{w}] \quad (10.95)$$

とした。

また、 $\ln q(\mathbf{w})$  は

$$\begin{aligned} \ln q^*(\mathbf{w}) &= \ln p(\mathbf{t}|\mathbf{w}) + E_{\alpha}[\ln p(\mathbf{w}|\alpha)] + \text{const} \\ &= -\frac{\beta}{2} \sum_{n=1}^N \{\mathbf{w}^T \boldsymbol{\phi}_n - t_n\}^2 - \frac{1}{2} E[\alpha] \mathbf{w}^T \mathbf{w} + \text{const} \\ &= -\frac{1}{2} \mathbf{w}^T (E[\alpha]I + \beta \Phi^T \Phi) \mathbf{w} + \beta \mathbf{w}^T \Phi^T \mathbf{t} + \text{const} \end{aligned}$$

これは、ガウス分布の対数であり

$$q^*(\mathbf{w}) = N(\mathbf{w}|\mathbf{m}_N, S_N) \quad (10.99)$$

となる。ここで

$$\mathbf{m}_N = \beta S_N \Phi^T \mathbf{t} \quad (10.100), \quad S_N = (E[\alpha]I + \beta \Phi^T \Phi)^{-1} \quad (10.101)$$

とした。

これらの計算には

$$E[\alpha] = \frac{a_N}{b_N} \quad (10.102), \quad E[\mathbf{w}^T \mathbf{w}] = \mathbf{m}_N \mathbf{m}_N^T + S_N \quad (10.103)$$

を用いて、交互に再推定していく。

変分線形回帰

1. まず  $q^*(\alpha)$  のパラメータを初期化する。
2.  $q^*(\mathbf{w})$  のパラメータを推定する。
3.  $q^*(\alpha)$  のパラメータを推定する。
4. 2,3 を繰り返す。

### 3 コード

変分線形回帰のコード (variational\_linear\_regression.py).

```
for N in [20,100,500]:
    x=data[:N,0]
    t=data[:N,1]
    for M in [4,10,20]:
        mu=[(m+0.5)*(2*pi/(M+1)) for m in range(M)]
        s=(2*pi)**2/12
        P=np.zeros((N,M))
        for n in range(N):
            for m in range(M):
                P[n,m]=polynomial_basis(x[n],m)
                #tanh_basis(x[n],m,mu[m],s)

        I=np.identity(M)

        beta=1/(0.3)**2
        a0,b0=1,1
        aN,bN=a0+M/2,1
        mN=np.zeros(M)
        SN=np.zeros((M,M))

        diff=10**6
        while diff>=10**-6:
            diff=0
            tmp=SN
            SN=inv(aN/bN*I+beta*dot(P.T,P))
            diff+=norm(tmp-SN)
            tmp=mN
            mN=beta*np.dot(SN,dot(P.T,t))
            diff+=norm(tmp-mN)
            tmp=bN
            bN=b0+trace(outer(mN,mN)+SN)/2
            diff+=abs(tmp-bN)
```

## 4 結果





$\alpha = 10^{-10}$ ,  $\beta = 1.0/(0.3)^2$  に固定して実験を行った.  
この  $\beta$  は元のデータの分散が  $(0.3)^2$  であることに由来する.  $\alpha$  については適当.

### 4.1 多項式基底

基底  $\Phi(x)$  に  $\phi_i(x) = x^i$  を選んだ. 「多項式曲線フィッティング」で行ったものと等しい.

M \ N	N		
	20	100	500
4	1.08	0.81	0.80
10	0.67	-	-
20	-	-	-

表 1:  $E_{RMS}$  の N,M との関係 (多項式基底)



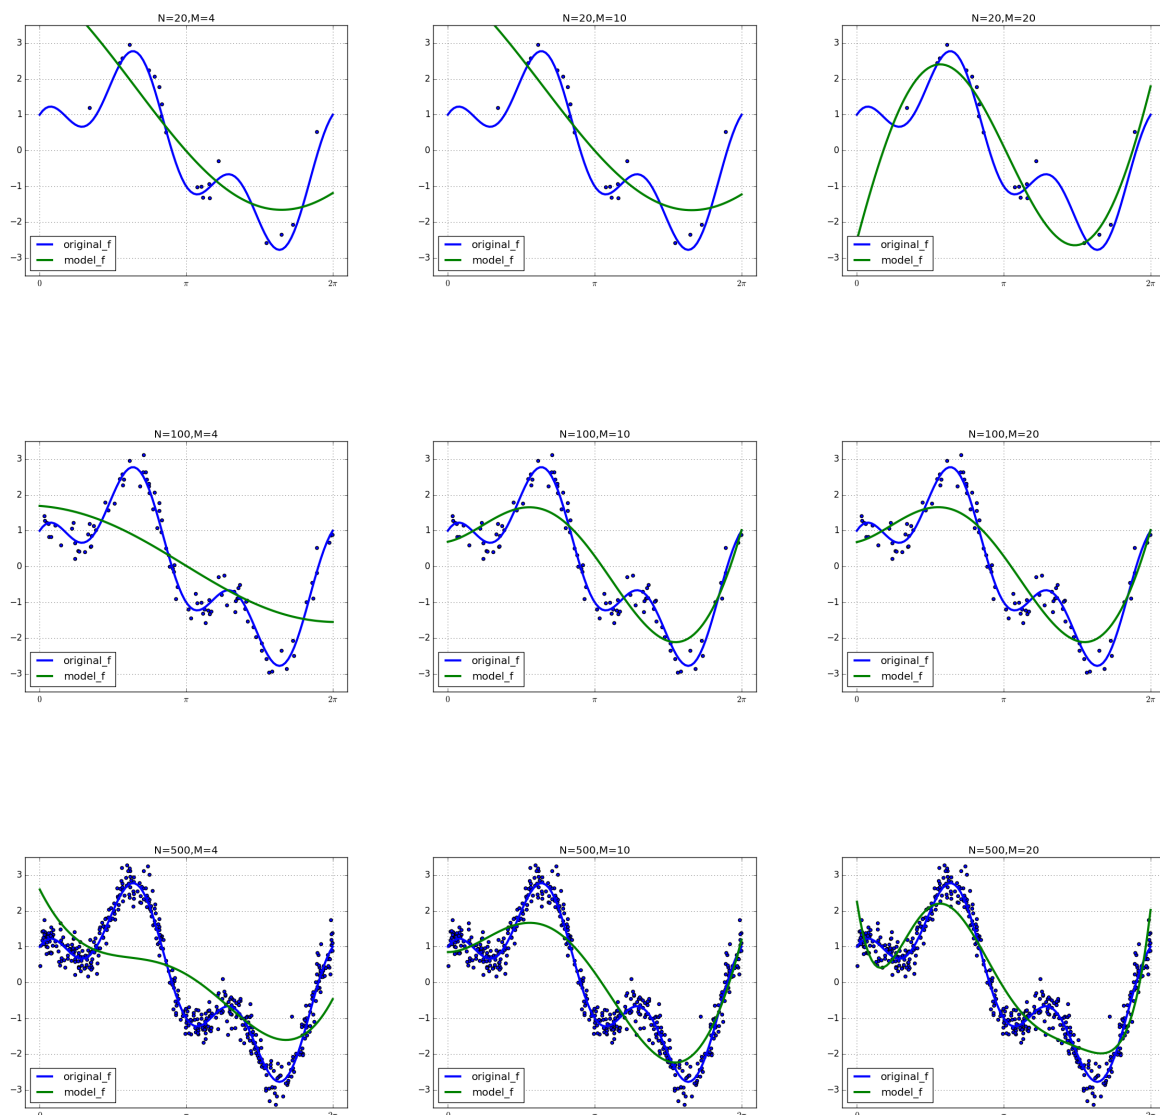
## 4.2 ガウス基底

基底  $\Phi(x)$  に  $\phi_i(x) = \exp\{-\frac{(x-\mu_i)^2}{2s^2}\}$  をもちいる. またここでは  $\mu$  は区間  $[0, 2\pi]$  を  $M$  個に等分する区間の中心を用い,  $s$  には  $x$  の分散を用いた.

$$\mu = [(m + 0.5) * (2 * \pi / (M + 1))] \text{ for } m \text{ in range}(M) \quad s = (2 * \pi) / M$$

M \ N	20	100	500
4	1.68	1.07	1.00
10	1.68	0.74	0.74
20	0.94	0.74	0.62

表 2:  $E_{RMS}$  の  $N, M$  との関係 (ガウス基底)

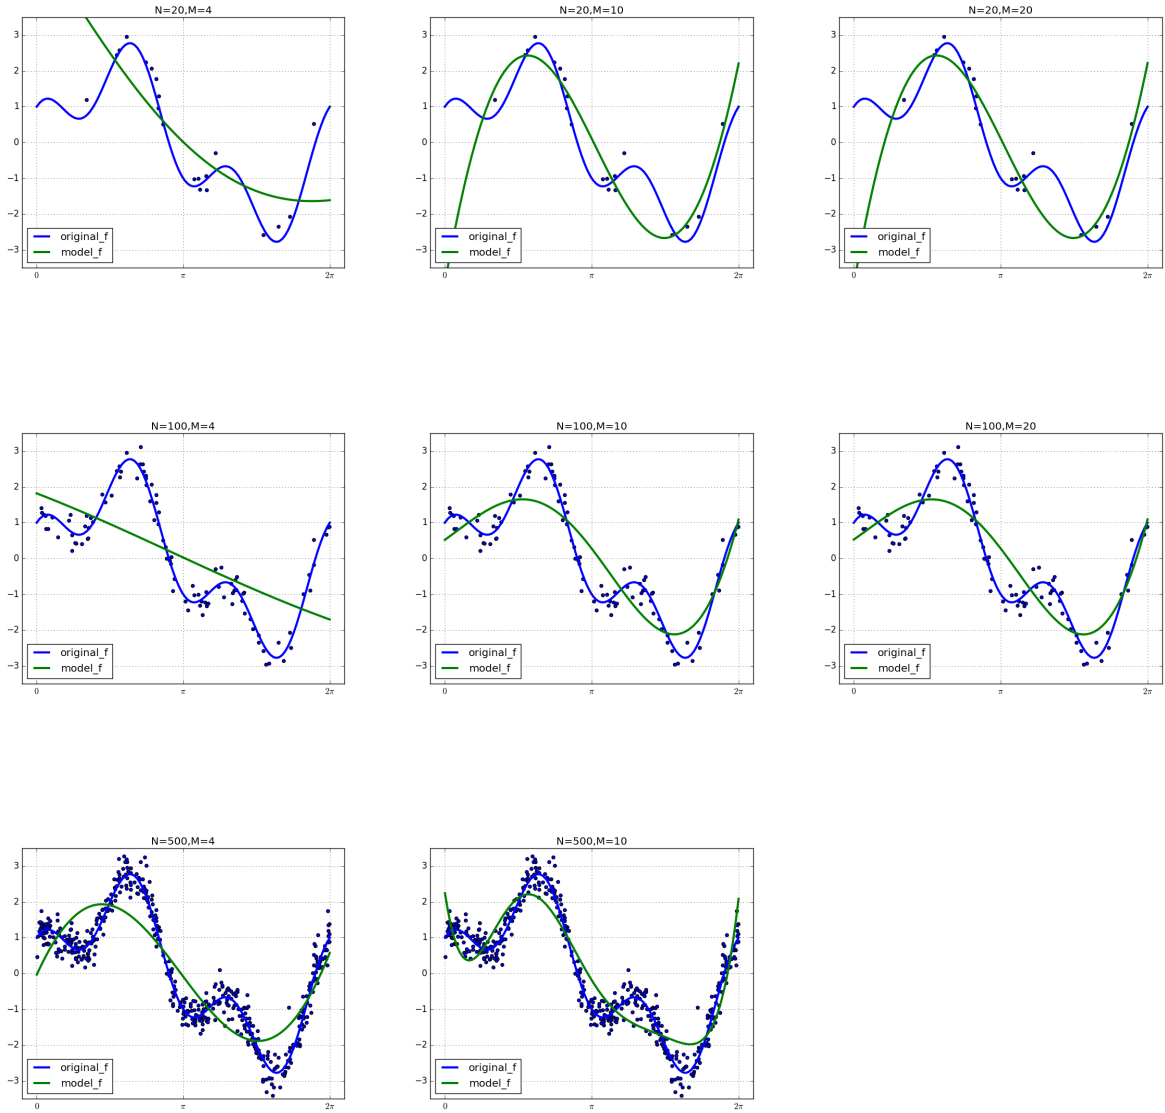


### 4.3 シグモイド基底

基底  $\Phi(x)$  に  $\phi_i(x) = \sigma(\frac{x-\mu_i}{s})$  をもちいる. ただし,  $\sigma(a) = \frac{1}{1+e^{-a}}$

M \ N	N		
	20	100	500
4	1.82	1.14	0.80
10	1.05	0.74	0.61
20	1.05	0.74	-

表 3:  $E_{RMS}$  の N,M との関係 (シグモイド基底)

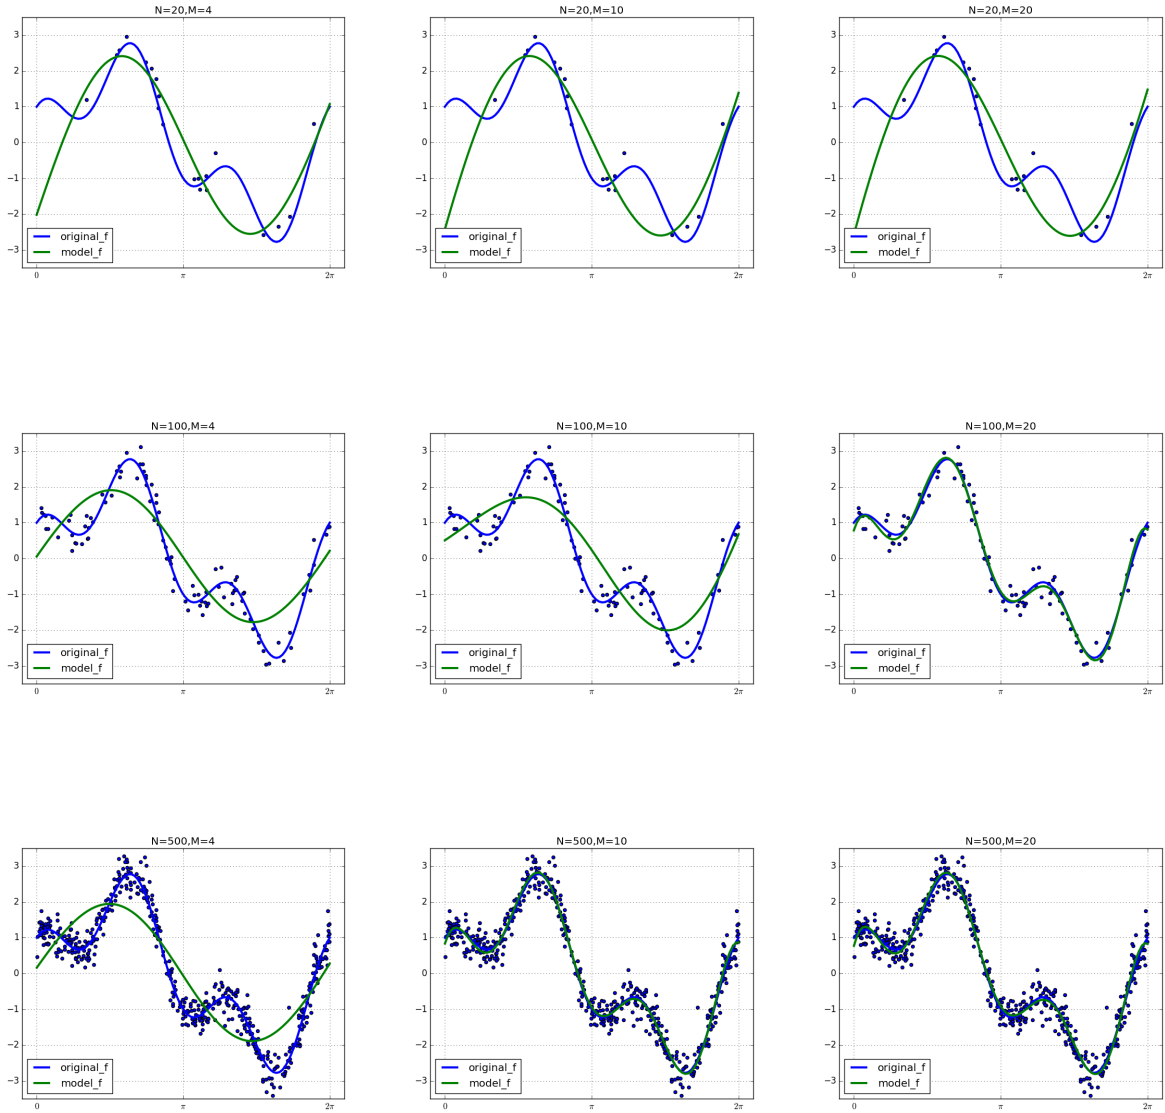


### 4.4 tanh 基底

基底  $\Phi(x)$  に  $\phi_i(x) = \tanh(\frac{x-\mu_i}{s})$  をもちいる.

M \ N	N		
	20	100	500
4	0.92	0.81	0.81
10	0.94	0.77	0.30
20	0.95	0.31	0.30

表 4:  $E_{RMS}$  の  $N, M$  との関係 ( $\tanh$  基底)



## 5 まとめ

毎回のよう、 $\tanh$  関数を基底関数とするのが一番よく、多項式基底はあまり良くない。繰り返しの要するので収束しないこともあった。